Atividade 2

Aluno: César Willian Pacheco

Suponha que você foi contratado por uma empresa do setor de saúde que precisa de um modelo preditivo para prever falhas cardíacas (infarto agudo).

A empresa preparou uma base de dados numérica, na qual cada instância foi rotulada de forma discreta como (1) *infarto* e (0) *normal*.

Leitura da base:

```
# carregando a base de dados
data = pd.read_csv("heart_failure_clinical_records_dataset.csv")

# recupera os valores e nomes de atributos a partir do dataframe
val=data.values
att=data.columns

# preparando os arrays X (atributos de entrada) e y (rótulos)
X = val[:,0:12]
y = val[:,12]
```

A) CONSTRUÇÃO DO MODELO: Encontrar a melhor solução para este problema por meio da avaliação de soluções monolíticas (uso de um único modelo). Para tal, avalie as técnicas estudadas em sala de aula (KNN, Naive Bayes, Árvores de Decisão, SVM, MLP e Ensembles). Utilize validação cruzada considerando 5 folds.

Anote na tabela abaixo o modelo **caixa preta** com melhor resultado, dê preferência para a métrica mais adequada considerando o problema em mãos.

Tabela de Resultados do Modelo Escolhido (Validação cruzada = 5 folds)

Classificador	Taxa de Acerto (%)	F1_score
Técnica: Random Forest Parâmetros: class_weight=None, max_depth=4, n_estimators=500	**85.95**	**0.7614**

Anote na tabela abaixo o modelo **caixa branca** com melhor resultado, dê preferência para a métrica mais adequada considerando o problema em mãos.

Tabela de Resultados do Modelo Escolhido (Validação cruzada = 5 folds)

Classificador	Taxa de Acerto (%)	F1_score
Técnica: Arvore de Decisao Parâmetros: criterion=entropy, max_depth=3, min_samples_leaf=10,	**82.27**	**0.7254**

min_samples_split=2		

Observação: F1_score refere-se à classe positiva (1 = infarto). Todos os valores foram obtidos por validação cruzada estratificada com 5 folds (StratifiedKFold, shuffle=True, random_state=42) sobre as 299 instâncias; a taxa de acerto e o F1 são calculados sobre as predições fora da amostra dos 5 folds (cross_val_predict). Os hiperparâmetros de cada técnica foram escolhidos por GridSearchCV (também com 5 folds, métrica F1). KNN, SVM e MLP usam StandardScaler dentro de um Pipeline. A tabela completa com todos os modelos avaliados encontra-se no Apêndice ao final deste documento.

B) Responda com base nas técnicas estudadas e nos resultados observados:

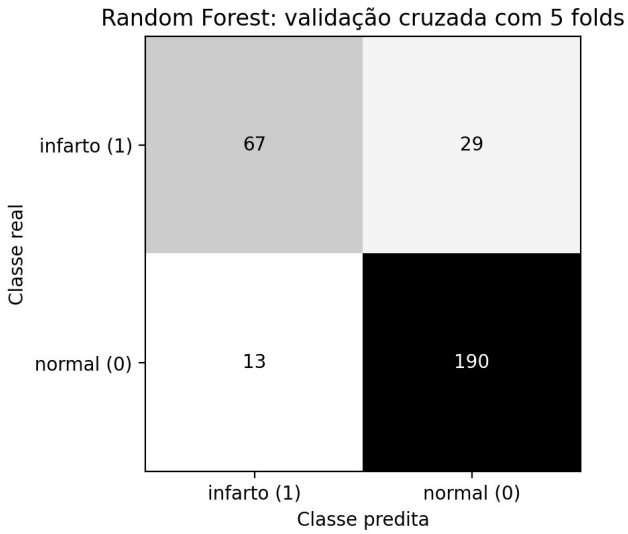
B.1) Quantas instâncias existem na base repassada pela empresa?
Resposta: 299 instâncias (pacientes).

B.2) Quantos atributos de entrada possui cada instância da base?
Resposta: 12 atributos de entrada: age, anaemia, creatinine_phosphokinase, diabetes, ejection_fraction, high_blood_pressure, platelets, serum_creatinine, serum_sodium, sex, smoking e time. O 13º atributo (DEATH_EVENT) é o rótulo.

B.3) Quantos exemplos de cada classe existem na base de dados?
Resposta: Classe 0 (normal): 203 exemplos (67.9%); classe 1 (infarto): 96 exemplos (32.1%). A base é desbalanceada (aproximadamente 2:1).

B.4) Nas tabelas acima, você apresentou seus melhores modelos de caixa-preta e de caixa-branca, segundo uma das métricas (Taxa de Acerto ou F1_score). Qual métrica você utilizou, Justifique sua escolha com base na métrica que julgar mais adequada (taxa de acerto ou F1_score).
Resposta: Utilizei o F1_score da classe positiva (infarto) como métrica de seleção dos modelos, reportando a taxa de acerto apenas como informação complementar.
Justificativa: a base é desbalanceada (203 normais contra 96 infartos). Um classificador trivial que respondesse sempre "normal" teria 67.9% de taxa de acerto sem detectar nenhum infarto, e a acurácia, portanto, esconde o desempenho na classe minoritária, que é justamente a classe de interesse clínico. O F1 é a média harmônica entre precisão (dos pacientes apontados como infarto, quantos realmente são) e revocação (dos infartos reais, quantos foram detectados) e só é alto quando as duas são altas, refletindo diretamente a capacidade do modelo de identificar corretamente os casos de infarto. Como os erros têm custos assimétricos (um falso negativo é um paciente de risco não identificado), o F1 é mais adequado que a taxa de acerto para este problema.

B.5) Apresente a matriz de confusão do modelo indicado na tabela e preencha abaixo:



Matriz de confusão do modelo Random Forest (soma dos 5 folds; linhas = classe real, colunas = classe predita). VP = 67, FN = 29, FP = 13, VN = 190.

- Taxa de verdadeiro positivo (VP): 67 casos → VP/(VP+FN) = 67/96 = 69.79% (sensibilidade / revocação)
- Taxa de falso positivo (FP): 13 casos → FP/(FP+VN) = 13/203 = 6.40%
- Taxa de verdadeiro negativo (VN): 190 casos → VN/(VN+FP) = 190/203 = 93.60% (especificidade)
- Taxa de falso negativo (FN): 29 casos → FN/(FN+VP) = 29/96 = 30.21%

B.6) A partir da matriz de confusão apresentada em B.5, calcule a taxa de acerto por classe.

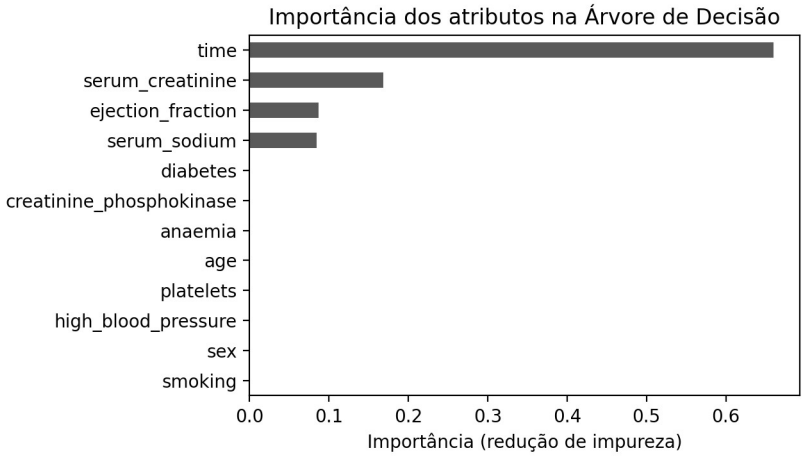
- Infarto: 67/96 = 69.79%
- Normal: 190/203 = 93.60%
- *Taxa de acerto geral = (VP+VN)/N = (67+190)/299 = 85.95%. O modelo acerta muito mais a classe majoritária (normal) do que a classe infarto, o que confirma a necessidade de olhar para o F1/revocação e não apenas para a taxa de acerto.*

B.7) Dentre os modelos caixa-branca avaliados, qual foi o melhor? Mostre os resultados (taxa de acerto e f1_score).

Modelo (técnica): Arvore de Decisao (criterion=entropy, max_depth=3, min_samples_leaf=10, min_samples_split=2)
Taxa de acerto: 82.27%
F1_score: 0.7254
Para comparação, o outro modelo caixa-branca avaliado, Naive Bayes (Gaussiano, var_smoothing=1e-09), obteve taxa de acerto de 79.93% e F1_score de 0.6203; a Árvore de Decisão foi superior nas duas métricas.

B.8) Considerando o uso de uma árvore de decisão para este problema, qual foi o atributo mais importante segundo esta técnica?

Nome do atributo (característica): time (tempo de acompanhamento, em dias)



O atributo time é a raiz da árvore (limiar 73,5 dias) e concentra 66% da redução total de impureza; em seguida vêm serum_creatinine (16,8%), ejection_fraction (8,7%) e serum_sodium (8,4%).

B.9) Dentre os modelos estudados, qual busca definir um hiperplano entre duas classes de forma a maximizar a margem de separação entre elas?
Resposta: A Máquina de Vetores de Suporte (SVM, Support Vector Machine). Ela escolhe, entre todos os hiperplanos que separam as duas classes, aquele que maximiza a margem, ou seja, a distância entre o hiperplano e os exemplos mais próximos de cada classe, chamados vetores de suporte. Com kernels (RBF, polinomial), o mesmo princípio é aplicado em um espaço de características de maior dimensão, permitindo fronteiras não lineares no espaço original.

B.10) Explique como a técnica Naive Bayes pode ser considerada uma simplificação do Teorema de Bayes.
Resposta: O Teorema de Bayes fornece a probabilidade a posteriori de uma classe c dado o vetor de atributos x: $P(c \mid x) = P(x \mid c) \cdot P(c) / P(x)$. Para classificar, escolhe-se a classe de maior $P(c \mid x)$ (regra MAP); como $P(x)$ é igual para todas as classes, basta maximizar $P(x \mid c) \cdot P(c)$.
O problema é estimar $P(x \mid c) = P(x1, x2, ..., xn \mid c)$, a probabilidade conjunta de todos os atributos dada a classe: isso exigiria uma probabilidade para cada combinação possível de valores de atributos (no exemplo PlayTennis, $2 \times 3 \times 3 \times 2 \times 2 = 72$ probabilidades condicionais), o que é inviável de estimar com bases de tamanho realista.
O Naive Bayes simplifica o teorema assumindo que os atributos são condicionalmente independentes dada a classe. Com isso, a probabilidade conjunta vira um produto de probabilidades individuais: $P(x \mid c) = P(x1 \mid c) \cdot P(x2 \mid c) \cdot ... \cdot P(xn \mid c)$, e o classificador passa a ser $c_NB = \text{argmax}_c\ P(c) \cdot \Pi\ P(xi \mid c)$. Cada $P(xi \mid c)$ é estimada de forma simples por frequência (atributos discretos) ou por uma distribuição normal por classe (Gaussian NB, usado nesta atividade). A hipótese é "ingênua" porque na prática os atributos costumam ser correlacionados, mas a regra de decisão argmax é robusta a probabilidades imprecisas e o método funciona bem em muitos problemas.

Questões gerais:

C.1) A máquina de vetores de suporte (SVM, *Support Vector Machine*) é originalmente um classificador binário. Contudo, podemos utilizá-lo para problemas de múltiplas classes usando as estratégias um-contra-todos ou todos-

contra-todos. A quantidade de classificadores a serem gerados pode variar conforme a estratégia utilizada. Considerando um problema com 5 classes, quais são as quantidades de classificadores gerados usando, respectivamente, um-contra-todos e todos-contra-todos?

Resposta: Um-contra-todos (one-vs-all): um classificador para cada classe → 5 classificadores.

Todos-contra-todos (one-vs-one): um classificador para cada par de classes → C(5,2) = 5 × 4 / 2 = 10 classificadores.

C.2) Cite abaixo três parâmetros que podem ser utilizados como mecanismos de poda na árvore de decisão implementada no scikit-learn.

Resposta: 1) max_depth: profundidade máxima da árvore (pré-poda; usado nesta atividade com valor 3).

2) min_samples_leaf: número mínimo de exemplos exigido em cada folha (usado com valor 10).

3) min_samples_split: número mínimo de exemplos em um nó para que ele possa ser dividido.

Outros mecanismos disponíveis no DecisionTreeClassifier: ccp_alpha (pós-poda por custo-complexidade), max_leaf_nodes e min_impurity_decrease.

Apêndice A: Resultados de todos os modelos avaliados (validação cruzada, 5 folds)

Ordenados por F1_score da classe infarto. VP/FN/FP/VN são as contagens agregadas das predições fora da amostra dos 5 folds.

Modelo	Tipo	Taxa de acerto (%)	F1 (infarto)	Precisão	Revocação	Melhores hiperparâmetros
Random Forest	caixa-preta	85.95	0.7614	0.8375	0.6979	class_weight=None, max_depth=4, n_estimators=500
Gradient Boosting	caixa-preta	84.28	0.7487	0.7692	0.7292	learning_rate=0.05, max_depth=2, n_estimators=200
AdaBoost	caixa-preta	83.95	0.7273	0.8000	0.6667	learning_rate=0.1, n_estimators=200
Arvore de Decisao	caixa-branca	82.27	0.7254	0.7216	0.7292	criterion=entropy, max_depth=3, min_samples_leaf=10, min_samples_split=2
Bagging (Arvores)	caixa-preta	82.61	0.7204	0.7444	0.6979	max_samples=0.5, n_estimators=200
SVM	caixa-preta	80.27	0.7204	0.6609	0.7917	C=0.1, class_weight=balanced, gamma=0.01, kernel=rbf
MLP	caixa-preta	80.94	0.7016	0.7053	0.6979	activation=relu, alpha=0.1, hidden_layer_sizes=(16, 8)
Voting (RF+SVM+KNN)	caixa-preta	81.94	0.6786	0.7917	0.5938	voting=hard
Naive Bayes	caixa-branca	79.93	0.6203	0.7903	0.5104	var_smoothing=1e-09
KNN	caixa-preta	74.58	0.5366	0.6471	0.4583	n_neighbors=3, p=1, weights=uniform

Apêndice B: Script utilizado

Os experimentos foram executados localmente em Python 3 com scikit-learn (não foi utilizado o Google Colab); por isso o script acompanha esta entrega como arquivo separado: atividade2_validacao_cruzada.py (junto com a base heart_failure_clinical_records_dataset.csv e a saída completa da execução em saida_atividade2.txt). Para reproduzir os resultados basta executar, na mesma pasta do CSV:

```
python atividade2_validacao_cruzada.py
```

Resumo do protocolo: leitura da base conforme o enunciado; StratifiedKFold(5, shuffle=True, random_state=42); GridSearchCV (scoring='f1') para KNN, Naive Bayes, Árvore de Decisão, SVM, MLP, Random Forest, AdaBoost, Bagging, Gradient Boosting e Voting; cross_val_predict com os mesmos folds para obter taxa de acerto, F1 e matriz de confusão; StandardScaler em Pipeline para KNN, SVM e MLP (ajustado apenas nos folds de treino, evitando vazamento de dados).